

WSI - Lista 1

Tomasz Niedziałek

April 1, 2025

1 Wstęp

Niniejsze sprawozdanie przedstawia wyniki trenowania sieci neuronowej do rozpoznawania cyfr z zestawu danych MNIST przy użyciu bibliotek TensorFlow i Keras. Wydajność sieci została oceniona na podstawie dokładności, precyzji i czułości na zbiorze testowym.

2 Architektura modelu

Model sieci neuronowej użyty w tym zadaniu to prosta sieć neuronowa typu feedforward o następującej architekturze:

- Warstwa wejściowa: Kształt (28, 28)
- Warstwa spłaszczająca: Konwertuje dane wejściowe 2D na wektor 1D
- Warstwa gęsta: 128 jednostek z funkcją aktywacji ReLU
- Warstwa dropout: Współczynnik dropout 20%
- Warstwa gęsta: 10 jednostek (warstwa wyjściowa)

Sieć neuronowa typu feedforward to najprostszy rodzaj sieci neuronowej, w której dane przepływają w jednym kierunku – od warstwy wejściowej, przez warstwy ukryte, aż do warstwy wyjściowej.

Funkcja aktywacji ReLU (Rectified Linear Unit) jest jedną z najczęściej używanych funkcji aktywacji w sieciach neuronowych. Zwraca wartość wejściową, jeśli jest dodatnia, lub 0, jeśli jest ujemna.

Dropout to technika regularizacji, która losowo "wyłącza" (zeruje) określony procent neuronów podczas treningu. W tym przypadku współczynnik dropout wynosi 20%, co oznacza, że 20% neuronów jest losowo wyłączanych w każdej iteracji. Technika ta pomaga zapobiegać przeuczeniu modelu (overfitting), zmuszając sieć do bardziej niezależnego uczenia się cech.

3 Trenowanie i ewaluacja

Model był trenowany przez 10 epok z użyciem optymalizatora Adam i funkcji straty sparse categorical cross-entropy. Podczas procesu trenowania monitorowano dokładność i stratę na zbiorach treningowym i walidacyjnym.

Optymalizator Adam (Adaptive Moment Estimation) jest jedną z najczęściej używanych metod optymalizacji w uczeniu maszynowym. Adam dynamicznie dostosowuje współczynniki uczenia dla każdego parametru modelu, wykorzystując średnie ruchome gradientów (pierwszy moment) oraz ich kwadratów (drugi moment). Dzięki temu optymalizator Adam jest szybki, efektywny i dobrze sprawdza się w przypadku dużych zbiorów danych oraz modeli z dużą liczbą parametrów.

Funkcja straty sparse categorical cross-entropy jest używana w zadaniach klasyfikacji wieloklasowej, gdzie etykiety są reprezentowane jako liczby całkowite (np. 0, 1, 2, ...). Funkcja ta oblicza różnicę między przewidywanymi prawdopodobieństwami (wyjściem modelu) a rzeczywistymi etykietami klas. Minimalizacja tej funkcji pozwala modelowi poprawić swoje przewidywania, dostosowując wagi w sieci neuronowej.

4 Wyniki

Poniżej przedstawiono wyniki uzyskane podczas trenowania i ewaluacji modelu:

- Początkowe wyjście softmax:

```
[[0.10025889, 0.10002384, 0.0999672, 0.09991807, 0.10014182,  
 0.10012015, 0.09991807, 0.09995951, 0.09994359, 0.09974883]]
```

Wyjście softmax to wektor prawdopodobieństw, który reprezentuje przewidywanie modelu dla każdej z 10 klas (cyfr od 0 do 9). Każda wartość w wektorze wskazuje prawdopodobieństwo, że dana próbka należy do danej klasy. Suma wszystkich wartości w wektorze wynosi 1.

- Początkowa strata: 2.3013842
- Końcowa dokładność treningowa: 91.51%
- Końcowa dokładność walidacyjna: 87.03%
- Końcowa dokładność testowa: 92.69%
- Końcowa strata testowa: 0.2501

5 Czulość i precyzja

Poniżej przedstawiono wyniki dotyczące czulości, precyzji oraz miary F1 dla poszczególnych klas:

Poniżej przedstawiono macierz pomyłek (confusion matrix) dla modelu:

Klasa	Precyzja	Czułość	Miara F1	Liczność (support)
0	0.94	0.98	0.96	980
1	0.96	0.98	0.97	1135
2	0.94	0.89	0.92	1032
3	0.91	0.91	0.91	1010
4	0.92	0.95	0.93	982
5	0.90	0.88	0.89	892
6	0.94	0.95	0.94	958
7	0.93	0.94	0.93	1028
8	0.88	0.89	0.89	974
9	0.94	0.90	0.92	1009
Dokładność	0.93 (na zbiorze testowym: 10000)			

Table 1: Wyniki precyzji, czułości i miary F1 dla poszczególnych klas.




Figure 1: Macierz pomyłek dla modelu.

6 Wnioski


Sieć neuronowa osiągnęła dokładność testową na poziomie 92.69%, co wskazuje na dobrą wydajność w rozpoznawaniu cyfr z zestawu danych MNIST. Wysoka dokładność sugeruje, że model dobrze generalizuje na nieznane dane.

7 Testowanie na własnych próbkach pisma

7.1 Wyniki testów

Na podstawie własnych próbek pisma, stworzono zbiór testowy zawierający pięć egzemplarzy każdej cyfry. Sieć neuronowa, stworzona w poprzednim punkcie, została przetestowana na tym zbiorze. Poniżej przedstawiono wyniki testów:

- Współczynnik rozpoznawalności: **34.00%**
- Macierz pomyłek (confusion matrix):



7.2 Wnioski

Współczynnik rozpoznawalności na własnych próbkach pisma wyniósł **34.00%**. Wynik ten jest znacznie niższy w porównaniu do wyników uzyskanych na zbiorze testowym MNIST, co może być spowodowane kilkoma czynnikami:

- **Różnice w stylu pisma:** Własne próbki pisma mogą różnić się stylem od próbek w zbiorze MNIST, co utrudnia sieci neuronowej poprawne rozpoznanie cyfr.
- **Jakość próbek:** Jakość własnych próbek pisma może być niższa (np. rozmazane, nierówne linie), co wpływa na dokładność rozpoznawania.
- **Liczba próbek:** Mniejsza liczba próbek w zbiorze testowym może prowadzić do mniej reprezentatywnych wyników.

7.3 Podsumowanie

Testowanie sieci neuronowej na własnych próbkach pisma wykazało, że model ma trudności z rozpoznawaniem cyfr w różnych stylach pisma. Współczynnik

rozpoznawalności wyniósł **34.00%**. Aby poprawić wyniki, można rozważyć dalsze trenowanie modelu na większej liczbie próbek pisma, w tym na próbkach o różnych stylach i jakościach. Można również zastosować techniki augmentacji danych, aby zwiększyć różnorodność zbioru treningowego.

8 Klasyfikator Random Forest do rozpoznawania cyfr

8.1 Wyniki testów

Klasyfikator Random Forest został wytrenowany i przetestowany na podanym zbiorze danych. Poniżej przedstawiono wyniki testów:

- Współczynnik prawidłowej rozpoznawalności (Accuracy): **96.80%**
- Precyzja, czułość oraz miara F1:

Cyfra	Precyzja	Czułość	Miara F1	Liczność (support)
0	0.97	0.99	0.98	980
1	0.99	0.99	0.99	1135
2	0.96	0.97	0.96	1032
3	0.96	0.96	0.96	1010
4	0.97	0.97	0.97	982
5	0.97	0.97	0.97	892
6	0.97	0.98	0.98	958
7	0.97	0.96	0.96	1028
8	0.96	0.95	0.96	974
9	0.95	0.95	0.95	1009

Table 2: Wyniki precyzji, czułości i miary F1 dla poszczególnych cyfr w klasyfikatorze Random Forest.

Poniżej przedstawiono macierz pomyłek (confusion matrix) dla klasyfikatora Random Forest:

8.2 Wnioski

Klasyfikator Random Forest osiągnął współczynnik prawidłowej rozpoznawalności na poziomie **96.80%** na zbiorze testowym. Precyzja, czułość oraz miara F1 dla każdej cyfry zostały przedstawione w tabeli powyżej. Wysoka dokładność oraz zrównoważone wartości precyzji i czułości wskazują, że klasyfikator dobrze radzi sobie z rozpoznawaniem cyfr z podanego zbioru danych.




Figure 2: Macierz pomyłek dla klasyfikatora Random Forest.